





Présentation de l'exercice d'ingénierie des données - projet numéro3

Contexte, objectifs et livrables du projet d'ingénierie
des données Laplace Immo

Pascal DUVAL

Datas scientist





Plan de l'exercice et Méthodologie Générale

Présentation structurée des étapes et conseils pour réussir l'exercice d'ingénierie des données



L'exercice : trois parties guidées

L'exercice se divise en trois phases : compréhension des données et création du dictionnaire, conception du schéma relationnel, puis chargement des données avec écriture des requêtes SQL et extraction des résultats.



Adopter une démarche précise

Il nous était demandé de lire l'ensemble du projet pour une vision globale, prendre des notes et synthétiser les éléments clés, préparer des questions pour les sessions avec le mentor, et suivre le cours sur la modélisation des bases de données.

Partie 1 : Compréhension des Données

Analyser et préparer un dictionnaire des données conforme et cohérent



Analyser les données disponibles pour préparer le dictionnaire

L'objectif principal est d'étudier les données existantes afin de structurer un dictionnaire des données complet et précis.



Comprendre les types de données spécifiques

Identifier les différents formats de données, par exemple : département 2A, 2B versus données numériques, pour assurer une bonne interprétation.



Respecter les règles de conformité RGPD et toutes les formes normales

Assurer la protection des données personnelles tout en appliquant des normes de modélisation relationnelle pour garantir l'intégrité des données.



Utiliser des outils simples et accessibles

Exploiter Excel pour faciliter l'analyse et la préparation du dictionnaire des données.



Livrer un dictionnaire des données complet et cohérent

Fournir un document final structuré qui sert de référence claire et fiable pour les données analysées.

L'Objectif

Le client demande l'extraction d'un certain nombre de données



Nombre total d'appartements vendus au 1er semestre 2020.



Le nombre de ventes d'appartement par région pour le 1er semestre 2020.



Proportion des ventes d'appartements par le nombre de pièces.



Liste des 10 départements où le prix du mètre carré est le plus élevé



Prix moyen du mètre carré d'une maison en Île-de-France.



Liste des 10 appartements les plus chers avec la région et le nombre de mètres carrés.



Taux d'évolution du nombre de ventes entre le premier et le second trimestre de 2020



Le classement des régions par rapport au prix au mètre carré des appartement de plus de 4 pièces.



Liste des communes ayant eu au moins 50 ventes au 1er trimestre



Différence en pourcentage du prix au mètre carré entre un appartement de 2 pièces et un appartement de 3 pièces




Les moyennes de valeurs foncières pour le top 3 des communes des départements 6, 13, 33, 59 et 69.



Les 20 communes avec le plus de transactions pour 1000 habitants pour les communes qui dépassent les 10 000 habitants

Déroulé du projet




Fournir un dictionnaire des données complet au format tableur

Ce dictionnaire détaille toutes les données utilisées dans l'exercice, facilitant la compréhension et la gestion des informations.



Présenter un schéma relationnel normalisé et justifié

Le schéma démontre la structure des données selon les règles de normalisation, avec des justifications précises pour chaque choix.




Créer et charger la base de données avec intégrité vérifiée

La base de données est opérationnelle et sa cohérence est assurée grâce à des contrôles d'intégrité rigoureux.



Réaliser un document SQL avec requêtes et résultats

Ce document compile les requêtes SQL exécutées ainsi que les résultats obtenus, illustrant les manipulations effectuées sur les données.




Préparer un support de présentation synthétisant démarche et résultats

Le support résume clairement la méthodologie suivie et les conclusions majeures de l'exercice pour un exposé efficace.

Partie 1 : Compréhension des Données

Analyse des données pour préparer un dictionnaire conforme et cohérent




Analyser les données disponibles pour préparer le dictionnaire

Examiner les données afin d'assurer une base solide pour la construction du dictionnaire des données.



Respecter les règles RGPD et les formes normales

Assurer la conformité légale et la normalisation des données pour une structure optimisée et sécurisée.



Livrer un dictionnaire des données complet et cohérent

Le résultat attendu est un dictionnaire structuré, clair et conforme aux normes définies.
Code, Signification, Type, Longueur, Nature, Règle de gestion, Règle de calcul (si besoin)


Dictionnaire de données des valeurs foncières

CODE	SIGNIFICATION	TYPE DE VARIABLES	LONGUEUR	NATURE (E/Ca/CO)	REGLE DE GESTION	REGLE DE CALCUL
Code service CH	Code du service de la conservation des hypothèques	VARCHAR	?	E	Peut être nul - utilisé pour identifier le service qui a enregistré la mutation	
Reference document	Référence unique du document notarié	VARCHAR	?	E	Peut être nul - identifiant juridique du document de mutation	
1 Articles CGI	Article du Code Général des Impôts applicable (1er)	VARCHAR	?	E	Peut être nul - complément possible à la colonne précédente	
2 Articles CGI	Article du Code Général des Impôts applicable (2e)	VARCHAR	?	E	Peut être nul - complément possible à la colonne précédente	
3 Articles CGI	Article du Code Général des Impôts applicable (3e)	VARCHAR	?	E	Peut être nul - complément possible à la colonne précédente	
4 Articles CGI	Article du Code Général des Impôts applicable (4e)	VARCHAR	?	E	Peut être nul - complément possible à la colonne précédente	
5 Articles CGI	Article du Code Général des Impôts applicable (5e)	VARCHAR	?	E	Peut être nul - complément possible à la colonne précédente	
No disposition	Numéro de disposition dans l'acte notarié	VARCHAR	?	E	Peut être nul	
Date mutation	Date à laquelle la mutation a été enregistrée	DATE	10	E	Format : aaaa/mm/jj	
Nature mutation	Type de mutation immobilière (vente, échange ?, etc. ?)	VARCHAR	10	E	Non nul - valeur dans une liste fermée	
Valeur fonciere	Montant total déclaré pour la mutation	INTEGER		E	Non nul - valeur ≥ 0	
No voie	Numéro dans la voie .. ? ..	VARCHAR	10	E	Possiblement nul	
B/T/Q	?	CHAR	1	E	Possiblement nul	
Code Type Voie	?	INTEGER		E	Non nul - valeur dans une liste fermée	
Type de voie	Rue Bld, Parc, etc..	VARCHAR	4	E	Non nul - valeur dans une liste fermée	
Code Voie	?	VARCHAR	5	E	Non nul	
Voie	Nom de la voie	VARCHAR	50	E	Ne peut être nul	
Code Id Commune	Code ID de la commune	INTEGER		E	Ne peut être nul	
Code postal	Code postal du bien concerné	VARCHAR	5	E	Doit respecter le format français (5 chiffres)	
Commune	Nom de la commune	VARCHAR	70	E	Ne peut être nul	
Code departement	Code INSEE du département	VARCHAR	3	E	Non nul	
Code commune	Code INSEE de la commune	VARCHAR	5	E	Non nul	
Prefixe de section	?	VARCHAR	3	E	Peut être nul	
Section	Section cadastrale ?	VARCHAR	4	E	Non nul – alphanumérique	
No plan	Numéro de plan cadastral ?	INTEGER		E	Non nul - numérique	
No Volume	?.	VARCHAR	10	E	Possiblement nul	
1er lot	Numéro du premier lot concerné	INTEGER		E	Possiblement nul	
Surface Carrez du 1er lot	en m²	FLOAT		E	Non nul	
2eme lot	Numéro du second lot concerné	INTEGER		E	Possiblement nul	
Surface Carrez du 2eme lot	en m²	FLOAT		E	Possiblement nul	
3eme lot	Numéro du troisième lot concerné	INTEGER		E	Possiblement nul	
Surface Carrez du 3eme lot	en m²	FLOAT		E	Possiblement nul	
4eme lot	Numéro du quatrième lot concerné	INTEGER		E	Possiblement nul	
Surface Carrez du 4eme lot	en m²	FLOAT		E	Possiblement nul	

Maîtriser la normalisation des bases de données - 1NF

Groupe répétitif sur 5 colonnes

Créer une relation séparée "Lot"





Bonnes Clés candidates ??

Réf doc et Code service CH souvent nuls → inutilisables comme clé.

Nouvelle clé

Créer un **ID technique** auto-incrémenté :
ID_Mutation PK.




Identifiant local comme clé primaire ??

Clé primaire ? → Dictionnaire indique
"Possiblement nul". Par ailleurs sémantique de
cet identifiant local et problème RGPD

Maîtriser la normalisation des bases de données 2NF & 3NF

2FN

Si la clé primaire est composée, alors chaque attribut non clé doit dépendre de toute la clé (pas d'une partie). Mais ici, nous avons maintenant une clé simple : ID_Mutation → Donc la 2FN est automatiquement respectée
Si la clé primaire est composée, alors chaque attribut non clé doit dépendre de toute la clé



3NF


Une table est en 3FN si chaque attribut non clé : Dépend directement de la clé primaire. Et pas d'un autre attribut non clé (pas de dépendance transitive) Or on a : ID_Mutation → CodeCommune → NomCommune
Donc il faut créer une table commune à part



Dictionnaire de données du référentiel géographique

CODE	SIGNIFICATION	TYPE DE VARIABLES	LONGUEUR	NATURE (E/Ca/CO)	REGLE DE GESTION	REGLE DE CALCUL
reggrp_nom	Nom du regroupement régional (Province – Ile-de-France, etc..)	VARCHAR	70	E	Non nul - valeur dans une liste fermée	
reg_nom	Nom de la région actuelle	VARCHAR	100	E	Non nul - valeur dans une liste fermé – standard administratif actuel	
reg_nom_old	Nom de l'ancienne région	VARCHAR	100	E	Non nul – valeur dans une liste fermé – utile pour comparaison historique	
aca_nom	Nom de l'académie	VARCHAR	50	E	Non nul	
dep_nom	Nom du département	VARCHAR	50	E	Non nul	
com_code	Code officiel de la commune (INSEE)	VARCHAR	5	E	Non nul ; format INSEE (5 chiffres)	
com_code1	Ancien code 1 de commune (ou format alternatif)	VARCHAR	5	E	Possiblement nul	
com_code2	Ancien code 2 de commune (ou format alternatif)	VARCHAR	5	E	Possiblement nul	
com_id	Identifiant technique de la commune (dans un base..)	VARCHAR	6	E	Non nul ; identifiant interne formaté	
com_nom_maj_cour	Nom court de la commune en majuscule (non utf-8)	VARCHAR	100	E	Peut être utilisé pour affichage compact	
com_nom_maj	Nom complet en majuscules (utf8)	VARCHAR	100	E	Utilisé pour homogénéisation des noms (avec tiret , accent, etc..)	
com_nom	Nom de la commune avec majuscules/minuscules	VARCHAR	100	E	Nom affiché standardisé	
uu_code	Code de l'unité urbaine (INSEE)	VARCHAR	10	E	Peut être nul	
uu_id	Identifiant technique de l'unité urbaine	VARCHAR	10	E	Peut être nul	
uucr_id	Identifiant technique du cœur d'unité urbaine	VARCHAR	10	E	Peut être nul	
uucr_nom	Nom du cœur d'unité urbaine	VARCHAR	100	E	Peut être nul	
ze_id	Identifiant de zone d'emploi (INSEE)	VARCHAR	10	E	Peut être nul – utilisé pour les analyses socio-éco	
dep_code	Code alphanumérique du département (ex : 2A)	VARCHAR	2	E	Non nul – format administratif officiel	
dep_id	Identifiant technique du département	VARCHAR	10	E	Non nul - utilisé en interne ?	
dep_nom_num	Nom + numéro du département	VARCHAR	100	CO	Non nul	Concaténation du nom et numéro (ex : Ain (01))
dep_num_nom	Numéro + nom du département	VARCHAR	100	CO	Non nul	Autre concaténation possible (ex : 01 - Ain)
aca_code	Code de l'académie	VARCHAR	5	E	Non nul ; identifiant du MEN (?)	
aca_id	Identifiant technique de l'académie	VARCHAR	10	E	Non nul ; utilisé en interne	
reg_code	Code INSEE de la région	VARCHAR	2	E	Non nul ; format officiel	
reg_id	Identifiant technique de la région	VARCHAR	10	E	Non nul ; utilisé en interne	
reg_code_old	Ancien code de région	VARCHAR	5	E	Possiblement nul ; utile pour historique	
reg_id_old	Ancien identifiant technique de région	VARCHAR	10	E	Possiblement nul	
fd_id	Identifiant d'une entité administrative supérieure	VARCHAR	10	E	Peut être nul ; utilisé en classification ESR	
fr_id	Identifiant régional ESR	VARCHAR	10	E	Peut être nul	
fe_id	Identifiant d'un échelon fonctionnel ESR	VARCHAR	10	E	Peut être nul	
uu_id_99	Identifiant de l'unité urbaine en 1999	VARCHAR	10	E	Peut être nul ; utile pour comparaisons historiques	
au_code	Code de l'aire urbaine (ancienne définition)	VARCHAR	10	E	Peut être nul	
au_id	Identifiant technique de l'aire urbaine	VARCHAR	10	E	Peut être nul	
auc_id	Identifiant du cœur d'aire urbaine	VARCHAR	10	E	Peut être nul	
auc_nom	Nom du cœur d'aire urbaine	VARCHAR	50	E	Peut être nul	
uu_id_10	Identifiant de l'unité urbaine de 2010 (?)	VARCHAR	10	E	Peut être nul	

1NF - 2NF & 3NF




2FN

2FN ne concerne que les tables avec une clé composée
Si la table a une clé simple ... pas de problème.
Prenons comme clé simple com_code..

1FN

geolocalisation : À remplacer par deux colonnes
: latitude, longitude
dep_nom_num, dep_num_nom mais on ne va
pas s'en servir



3FN


Une table est en 3FN si elle est en 2FN, et si
aucun attribut non clé ne dépend d'un autre
attribut non clé (i.e. pas de dépendance
transitive)

Dictionnaire de données communes

CODE	SIGNIFICATION	TYPE DE VARIABLES	LONGUEUR	NATURE (E/Ca/CO)	REGLE DE GESTION	REGLE DE CALCUL
CODREG	Code de la région (INSEE)	VARCHAR	2	E	Obligatoire ; valeurs codifiées officielles	
CODDEP	Code du département	VARCHAR	2	E	Obligatoire ; format INSEE ; ex : 01, 2A, etc.	
CODARR	Code de l'arrondissement	VARCHAR	2	E	Obligatoire ; découpage administratif	
CODCAN	Code du canton	VARCHAR	2	E	Obligatoire ; subdivision de l'arrondissement	
CODCOM	Code de la commune (au sein du département)	VARCHAR	3	E	Obligatoire	souvent joint avec CODDEP pour former le code INSEE
COM	Nom officiel de la commune	VARCHAR	100	E	Non nul ; nom administratif selon INSEE	
PMUN	Population municipale	INTEGER		E	≥ 0 ; population résidant sur le territoire communal	
PCAP	Population comptée à part	INTEGER		E	≥ 0 ; personnes rattachées administrativement mais non résidentes	
PTOT	Population totale	INTEGER		Ca	Non nul	somme des colonnes PMUN + PCAP

Partie 2 : Conception du Schéma Relationnel

Création et adaptation d'un schéma relationnel conforme aux besoins métier



Objectif de la conception


Adapter un schéma relationnel répondant aux besoins métier spécifiques.

Base de départ

Utiliser l'ébauche fournie et le modifier pour l'adapter aux besoins

Implémenter physiquement

Schéma relationnel mis à jour ou créé, prêt à être intégré dans SQLite



L'Objectif (bis)

Le client dema,de l'extraction d'un certain nimbre de données



Nombre total d'appartements vendus au 1er semestre 2020.



Le nombre de ventes d'appartement par région pour le 1er semestre 2020.



Proportion des ventes d'appartements par le nombre de pièces.



Liste des 10 départements où le prix du mètre carré est le plus élevé



Prix moyen du mètre carré d'une maison en Île-de-France.



Liste des 10 appartements les plus chers avec la région et le nombre de mètres carrés.



Taux d'évolution du nombre de ventes entre le premier et le second trimestre de 2020



Le classement des régions par rapport au prix au mètre carré des appartement de plus de 4 pièces.



Liste des communes ayant eu au moins 50 ventes au 1er trimestre



Différence en pourcentage du prix au mètre carré entre un appartement de 2 pièces et un appartement de 3 pièces



Les moyennes de valeurs foncières pour le top 3 des communes des départements 6, 13, 33, 59 et 69.



Les 20 communes avec le plus de transactions pour 1000 habitants pour les communes qui dépassent les 10 000 habitants

Analyse requête par requête

	Attributs disponibles	Filtre ?	Faisable en l'état	Manque 1	Manque 2
Nombre total d'appartements vendus au 1er semestre 2020	✓ Type_local, Date → disponibles	Il faut filtrer sur Type_local = 'Appartement'	oui	X	X
Nombre de ventes d'appartements par région pour le 1er semestre 2020	X	Il faut filtrer sur La date de la mutation (on a !)	non	Manque la région dans le schéma	I faut une table Departement avec : Code_departement → Code_region (ou Nom_region) Et une jointure Commune → Departement → Region
Proportion des ventes d'appartements par le nombre de pièces	✓ Type_local = 'Appartement' ✓ Total_piece → présent		Oui		

Analyse requête par requête

	Attributs disponibles	Filtre ?	Faisable en l'état	Manque 1	Manque 2
Taux d'évolution des ventes entre T1 et T2 2020	✓ Date → suffisant pour filtrer par trimestre		oui	X	X
Classement des régions par prix au m² des appartements de +4 pièces	✓ Type_local = 'Appartement', Total_piece > 4, Valeur, Surface_carrez → OK		non	Manque la région	
Liste des communes ayant eu ≥ 50 ventes au 1er trimestre	✓ id_coddep_codecommune → OK ✓ Date → OK		oui	Ce serait mieux avec le nom de la commune ...	

Analyse requête par requête

	Attributs disponibles	Filtre ?	Faisable en l'état	Manque 1	Manque 2
Les 10 départements où le prix du m ² est le plus élevé	✓ Valeur, Surface_carrez, Code_departement	Peut poser problème si Surface_carrez = 0 → prévoir filtre	oui	X	X
Prix moyen du m ² d'une maison en Île-de-France pour le 1er semestre 2020	✓ Type_local = 'Maison', Valeur, Surface_carrez → OK	idem	non	Manque la région pour filtrer sur "Île-de-France"	
Les 10 appartements les plus chers avec la région et le nombre de m ²	✓ Valeur, Type_local, Surface_carrez → OK	idem	non	Manque la région	Manque une jointure Bien → Commune → Département → Région

Analyse requête par requête

	Attributs disponibles	Filtre ?	Faisable en l'état	Manque 1		Manque 2	
Différence en % du prix/m² entre un appart. 2 pièces et un appart. 3 pièces	✓ Type_local = 'Appartement' ✓ Total_piece = 2 ou 3 ✓ Valeur, Surface_carrez		oui	X		X	
Valeurs moyennes pour le top 3 des communes dans départements 6, 13, 33, 59, 69	✓ Code_departement, Nom_commune, Valeur		non	Manque la population		X	
20 communes avec le plus de ventes pour 1000 habitants (si >10k habitants)	Idem		non	il manque le nombre d'habitants (population) de chaque commune !		Ajouter une table Démographie : Demographie (id_coddep_codec ommune (PK/FK), population)	

Synthèse : ce qu'il manque au schéma

Region

Région par Commune

Population par Commune

Requête par trimestre

Type de bien

Surface & pièces



Absent

Currently impossible

Absent

OK (Date présente)

OK (**Type_local** présent)

OK (**Surface_carrez**, Surface_locale **Total_piece**)




Ajouter une table **Departement** liée à la **Region**

Créer un relation **Commune** → **Departement** → **Region**

Ajouter cet attribut à la table Commune

Aucune addition Requise

Aucune addition Requise




Analyse détaillée des ventes immobilières en 2020

Présentation des statistiques clés sur les ventes d'appartements et maisons au 1er semestre 2020 par région et département

Non	Rép	Top	Prix	Liste	Évol
de	des	10m	moy	des	du
Clas	Con	Diffé	Vale	Top	nom
vent	vent	avec	du	10 ^p	
des	avec	en	moy	20	
Présentation des	Analyse de la	Classement des	Détail du prix	Identification des	Taux d'évolution

Etudier le marché immobilier

SQL JOINS



31,378

Nbr d'appartements vendus (T1 2020)

```
SELECT COUNT(*) AS nb_appartements_vendus FROM Vente v JOIN Bien b ON v.id_bien = b.id_bien WHERE b.type_local = 'Appartement' AND v.date BETWEEN '2020-01-01' AND '2020-06-30';
```

3,997.26


Prix moyen du m2 en Île-de-France (Maisons)

Calcul du prix moyen au m2 des maisons en Île-de-France basé sur les ventes récentes.

```
ROUND(AVG(v.valeur / b.surface_local), 2) AS prix_m2_moyen_maison_idf
```

```
FROM Vente v
JOIN Bien b ON v.id_bien = b.id_bien
JOIN Commune c ON b.id_coddep_codecommune = c.id_coddep_codecommune
JOIN Departement d ON c.code_departement = d.code_departement
JOIN Region r ON d.code_region = r.code_region
WHERE b.type_local = 'Maison'
AND b.surface_local > 0
AND v.valeur IS NOT NULL
AND r.nom_region = 'Ile-de-France';
```


Partie 3 : SQL Queries



1. La base de données est prête et complètement chargée

La base de données a été créée et entièrement chargée avec toutes les données nécessaires, ce qui permet une progression fluide vers l'extraction des données à l'aide de SQL.



2. Documentation des requêtes

Chaque requête et son résultat sont données dans un fichier à part